

ВЫВОДЫ ПО ДАТАСЕТУ

Перечень субсидий, предоставленных организациям, осуществляющим деятельность в инновационной и промышленной сферах

Домашнее задание № 1, нулевой модуль магистратуры «Искусственный интеллект»,
НИУ ВШЭ

1. Описание датасета

Для разведочного анализа выбран набор открытых данных № 591 «Перечень субсидий, предоставленных организациям, осуществляющим деятельность в инновационной и промышленной сферах», опубликованный на портале открытых данных Правительства Москвы (data.mos.ru/opendata/591). Поставщик данных – Департамент инвестиционной и промышленной политики города Москвы. Использована выгрузка в формате XLSX, версия от 17.04.2018.

Набор представляет собой реестр договоров субсидий, заключенных городом с промышленными и инновационными организациями. Объем – 270 записей и 7 столбцов. Каждая запись описывает один договор: наименование проекта или меры поддержки, получателя субсидии, годы начала и окончания действия договора и сумму субсидии в рублях. Договоры заключены в 2012–2017 годах, срок действия отдельных из них продлевается до 2025 года. Совокупная сумма по всем договорам составляет 11,64 млрд рублей.

Состав столбцов приведен в таблице 1.

Таблица 1. Структура набора данных

Столбец	Содержание	Тип
Код	Порядковый номер записи в реестре	целое
Наименование	Название проекта или меры поддержки	текст
Получатель субсидии	Наименование организации-получателя	текст
global_id	Сквозной идентификатор записи на портале	целое
Начало действия договора субсидии	Год заключения договора	целое
Конец действия договора субсидии	Год окончания договора	целое
Сумма субсидии по договору (руб.)	Сумма субсидии в рублях	целое

2. Результаты разведочного анализа

Распределение сумм субсидий крайне неравномерно. Медианный договор составляет 7,0 млн рублей, тогда как среднее значение – 43,1 млн рублей, то есть в шесть раз выше. Коэффициент асимметрии равен 4,7. Нижний квартиль составляет 5,08 млн рублей, верхний – 21,8 млн рублей, при этом 95-й процентиль достигает 194,6 млн рублей, а максимальный договор – 865 млн рублей. Десять крупнейших договоров дают 48,7 % всей суммы субсидий. Из этого следует, что средняя сумма субсидии как показатель непригодна: набор описывается медианой и квантилями, а крупнейшие договоры рассматриваются отдельно.

Объем поддержки последовательно растет на всем периоде наблюдения. Число договоров увеличилось с 24 в 2012 году до 68 в 2017 году, суммарный объем – с 0,22 до 4,71 млрд рублей. При этом медианный размер договора оставался в диапазоне 7,0–9,9 млн рублей и вырос до 17,0 млн рублей только в 2017 году, а линейная связь года и суммы договора слабая (коэффициент корреляции 0,15). Таким образом, рост совокупного объема поддержки обеспечен увеличением числа получателей и отдельными крупными договорами, а не общим удорожанием типового договора.

Таблица 2. Распределение договоров по году начала действия

Год	Договоров, ед.	Сумма, млрд руб.	Медиана договора, млн руб.
2012	24	0,22	9,50
2013	31	1,14	9,86
2014	35	0,84	9,42
2015	55	1,88	7,00
2016	57	2,85	7,00
2017	68	4,71	16,96
Итого	270	11,64	7,00

По срокам действия преобладают трехлетние договоры – 177 из 270. Однолетних договоров 37, двухлетних – 29, четырехлетних – 24, шестилетних – 2, десятилетний – один. Договоров, у которых год окончания предшествует году начала, в наборе нет.

3. Проблемы в данных

Формальные показатели качества у набора высокие: пропущенных значений нет ни в одном из семи столбцов, пустых строк нет, полные дубликаты записей отсутствуют, столбцы «Код» и «global_id» уникальны, дубликатов по смысловому ключу (наименование, получатель, сумма) также не обнаружено. Тем не менее для анализа набор в исходном виде непригоден по перечисленным ниже причинам.

Первая строка выгрузки не является наблюдением. В ней продублированы русские подписи к техническим именам столбцов. Из-за этой строки все семь столбцов читаются как текстовые, включая суммы и годы, и расчет любых статистик становится невозможен. Строку требуется удалять вручную, после чего числовые столбцы приводить к целому типу. Брака при приведении не возникает: все 270 значений в каждом из трех числовых столбцов разбираются как числа.

Текстовые поля содержат служебные символы. В столбце «Наименование» 48 значений включают перенос строки внутри значения и 40 значений – лишние пробелы по краям; в столбце «Получатель субсидии» – 35 и 25 значений соответственно. Всего 83 значения содержат переносы строк. Это следы копирования из текстовых документов. Такие символы делают невозможным сравнение и группировку строк: два визуально одинаковых наименования считаются разными значениями.

Неявные дубликаты получателей субсидий – основной дефект набора. Одна и та же организация записана в нескольких формах: с полной организационно-правовой формой, с сокращенной, в разном регистре. Например, Казенное предприятие города Москвы «Корпорация развития Зеленограда» встречается в трех вариантах написания, Акционерное общество «Эпизл» – также в трех, причем в одном из них указана устаревшая организационно-правовая форма закрытого акционерного общества. Формально в наборе 234 уникальных получателя, после снятия организационно-правовых форм и кавычек остается 206. Следовательно, не менее 28 организаций задвоены, и определить по этому набору число организаций, получивших поддержку, нельзя. Идентификаторы юридических лиц – ИНН или ОГРН – в наборе отсутствуют, поэтому надежно свести записи по одной организации невозможно; сопоставление наименований остается приблизительным.

В двух записях указаны аномальные суммы субсидии: 1 рубль по договору с Закрытым акционерным обществом «ПАРТНЕР Ф» и 3 рубля по договору с Акционерным обществом «Корпорация «ВНИИЭМ»». Оба договора относятся к возмещению части затрат на уплату

лизинговых платежей. Субсидия в размере одного рубля экономического смысла не имеет, поэтому значения следует рассматривать как ошибку ввода либо как результат усечения суммы при выгрузке. При расчете совокупных показателей такие записи требуется исключать.

Столбцы начала и окончания действия договора названы как даты, но содержат только год. Точность до года не позволяет рассчитать фактическую длительность договора и рассмотреть внутригодовое распределение заключенных договоров.

Столбцы «Код» и «global_id» дублируют друг друга по назначению: оба являются сквозными уникальными идентификаторами записи. Профилирующий отчет фиксирует высокую взаимную корреляцию этих столбцов. Для анализа достаточно одного из них.

Набор описывает период 2012–2017 годов и выгружен в 2018 году, тогда как отдельные договоры формально действуют до 2025 года. Данные с момента выгрузки не обновлялись. Для оценки текущего состояния поддержки промышленных организаций набор непригоден и может использоваться только для ретроспективного анализа.

4. Заключение

Набор пригоден для анализа после подготовки: удаления служебной строки заголовков, приведения числовых столбцов к целому типу, очистки текстовых полей от переносов строк и лишних пробелов, исключения двух записей с аномальными суммами. Основное ограничение снять не удастся: без идентификаторов юридических лиц свести записи по одной организации можно только приблизительно, поэтому выводы в разрезе получателей субсидий будут приблизительноными. Показатели в разрезе года заключения договора и суммы субсидии рассчитываются корректно.